

# Reconocimiento de Actividades de la Vida Diaria

## Proyecto Integrativo II

Autoras: Garcia Navarro Arandy

Rodriguez Ponce Valeria

Camacho Fragoso Andrea

Guzmán Delgadillo Paola

Profesores: José Eduardo Chairez Veloz

Gustavo Pacheco Santiago

Luis Enrique Nava García

Ayudante: Misael Saúl Ávila López

Fecha: 3 de noviembre de 2025

### Resumen

En el presente trabajo se presenta el desarrollo de un sistema para el reconocimiento de actividades de la vida diaria (ADL), en este caso el salto dividido en 3 partes, el estar estatico, el impulso y el salto; empleando sensores iniciales tipo IMU (WT9011DCL). Se describe el protocolo experimental, la adquisición de datos, la extracción y selección de características, así como la evaluación de distintos modelos de clasificación. Los resultados enseñan el comportamiento del modelo en esta actividad, permitiendo detectar si existe salto o no y si hay posibles formas de mejorar para implementarlo en la ciencia.

## 1. Introducción

El estudio de las *Actividades de la Vida Diaria* (ADL) mediante sistemas automatizados es un área de creciente interés en el ámbito deportivo y biomédico. En este trabajo nos enfocamos en la detección y clasificación automática del salto, ya que es un indicador en la potencia y explosividad del tren inferior, así como de la condición física general. Poder medir y analizar patrones de salto permite evaluar programas de entrenamiento, identificar fortalezas y debilidades musculares, y monitorear el rendimiento en deportes donde las acciones aéreas son fundamentales.

Desde el punto de vista biomédico, la clasificación de movimientos básicos como el salto y el reposo es especialmente relevante para el monitoreo de pacientes en rehabilitación y adultos mayores. Según la Organización Mundial de la Salud (OMS), las caídas son una de las principales causas de lesiones en adultos mayores, lo que ha motivado el desarrollo de sistemas automáticos para detectar y clasificar patrones de movimiento con el fin de prevenir accidentes.

Las Unidades de Medición Inercial (IMU), como el sensor WT9011DCL, permiten registrar aceleraciones y velocidades angulares en tiempo real de forma práctica y no invasiva. Esto las hace herramientas ideales para adquirir datos biomecánicos en condiciones naturales de movimiento.

El objetivo de este trabajo es diseñar e implementar un sistema que adquiera y procese datos de un sensor IMU para clasificar dos estados de movimiento: salto y reposo. Para lograrlo, utilizamos técnicas de procesamiento digital de señales y algoritmos de aprendizaje automático como Python y Orange, que permiten distinguir automáticamente entre ambos estados.

## 2. Metodología

La metodología se divide en cuatro etapas principales:

- Protocolo Experimental y la Carta de consentimiento.
- Extraccion de datos, incluyendo el filtrado
- Selección de características
- Clasificacion de Actividades
- Escoger un modelo de la aplicación de Orange para su aprendizaje.

### 2.1. Protocolo experimental

Para la adquisición de las señales iniciales correspondientes a la secuencia de actividad: Estar quieto-Impulso-Salto se utilizó el sensor inercial **WT9011DCL** en una serie de sujetos, tomando como punto de medida el tobillo (como se muestra en la Figura 1) que es uno de los elementos clave para la marcha, el salto y otras actividades de la vida diaria. Los datos se capturaron con una frecuencia de muestreo de 200 Hz.

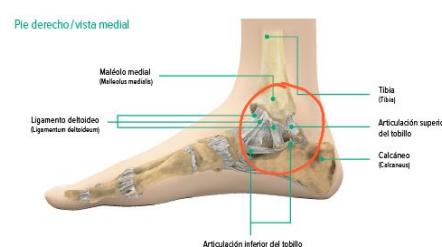
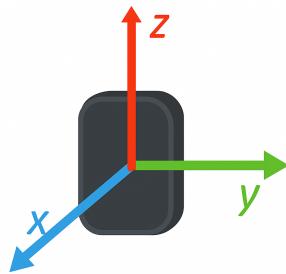


Figura 1: Posición del sensor en el pie derecho

Para comenzar se definió la colocación del sensor, apar-

tir de la palpación del hueso del tobillo: astrágalo como punto de referencia para todos los sujetos, el sensor se colocó al lado de este; Al tener el sensor colocado en la parte interna del pie derecho, se calibro para que la posición de los ejes se vean de la siguiente manera:



**Figura 2:** Representación gráfica de los ejes en el sensor

Para la adquisición del ciclo completo la prueba se dividió en dos secciones: una sección en reposo y una en movimiento. Inicialmente el sujeto comenzó la prueba sentado en una silla (ésto para que al colocarse de pie adoptara la posición de estar quieto lo más natural posible) posteriormente se le indicó (justo cuando dió inicio la adquisición de señales) que se levantara de su asiento y se procedió como en el Anexo A a seguir diferentes pasos en diferentes condiciones como por ejemplos:

- 30 seg de no movilidad
- 10 saltos continuos de forma vertical

## 2.2. Extracción de características

A partir de la adquisición de las señales "crudas", se establecieron una serie de características que definen y caracterizan las señales adquiridas, para este caso se determinaron características tanto en el dominio del tiempo (media, varianza, energía y curtosis), así como en el dominio de la frecuencia por medio de la Transformada Rápida de Fourier (FFT) (Cuadro 3-Anexo). Al realizar la Transformada se obtuvieron un total de **22 ventanas** por cada sujeto de prueba.

## 2.3. Selección de características

Las características extraídas de los sensores iniciales (acelerómetro y giróscopo) fueron seleccionadas por su capacidad para describir de manera integral el movimiento humano. En conjunto, estas variables capturan tres dimensiones principales del comportamiento dinámico:

Magnitud e intensidad del movimiento, mediante métricas como el RMS, la energía total y la varianza, que reflejan el nivel de actividad física y la estabilidad del movimiento.

Regularidad y cadencia, representadas por la frecuencia dominante y la entropía espectral, que permiten identificar patrones periódicos y la complejidad del movimiento.

Orientación y coordinación espacial, evaluadas a través de la media, correlaciones entre ejes y parámetros rotacionales, útiles para distinguir posturas, inclinaciones y movimientos coordinados.

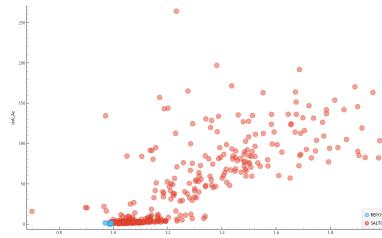
Estas características, combinadas, ofrecen una descripción robusta del movimiento, facilitando la discriminación entre distintos tipos de actividad, como reposo, caminar o saltar

## 2.4. Clasificación

Para la continuación del trabajo se seleccionó el modelo SVM para clasificar los diferentes estados (reposo y salto) de los datos, debido a su capacidad para manejar eficientemente múltiples variables. Este permite separar claramente las clases en un espacio multidimensional y ofrece un buen punto de equilibrio y precisión.

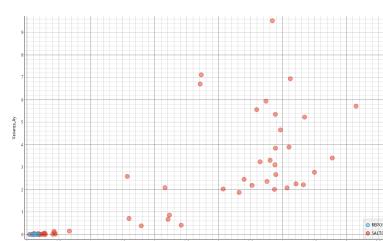
## 3. Resultados y Discusión

Al procesar los datos dentro de la aplicación *Orange*, se obtuvo la gráfica 3, en la que se observa el comportamiento de las señales durante el salto y el reposo. Los puntos azules representan el estado de **reposo**, y los rojos, el **salto**.



**Figura 3:** Comportamiento de las señales durante salto y reposo.

Después de aplicar el modelo SVM, el comportamiento cambia como se muestra en la figura 4.



**Figura 4:** Resultado del modelo SVM aplicado a las señales.

El análisis muestra que las confusiones más frecuentes ocurren entre actividades con patrones de aceleración similares, como caminar y subir escaleras. El sistema es viable para aplicaciones biomédicas por su alta precisión y bajo costo computacional.

Para evaluar el desempeño del modelo SVM, se emplearon las métricas comunes en aprendizaje automático: **Exactitud (Accuracy)**, **Precisión (Precision)**,

sion), Sensibilidad (Recall), Especificidad (Specificity), Valor Predictivo Positivo (PPV), Valor Predictivo Negativo (NPV) y F1-Score.

## Matriz de Confusión

**Cuadro 1:** Matriz de confusión del modelo de clasificación.

Actual / Predicha	REPOSO	SALTO	$\Sigma$
REPOSO	2	3	5
SALTO	0	68	68
$\Sigma$	2	71	73

A partir de la matriz de confusión se obtienen los siguientes valores:

$$TP = 68, \quad TN = 2, \quad FP = 3, \quad FN = 0$$

## Fórmulas de las métricas de evaluación

$$\text{Exactitud (Accuracy)} : ACC = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precisión (Precision / PPV)} : PREC = \frac{TP}{TP + FP}$$

$$\text{Sensibilidad (Recall)} : RECALL = \frac{TP}{TP + FN}$$

$$\text{Especificidad (Specificity)} : SPEC = \frac{TN}{TN + FP}$$

$$\text{Valor Predictivo Negativo (NPV)} : NPV = \frac{TN}{TN + FN}$$

$$\text{F1-Score} : F1 = 2 \cdot \frac{PREC \cdot RECALL}{PREC + RECALL}$$

## Resultados obtenidos

### Exactitud (Accuracy):

$$ACC = \frac{68 + 2}{68 + 2 + 3 + 0} = \frac{70}{73} = 0,9589 \Rightarrow \text{Exactitud} = 95.89\%$$

### Precisión (Precision):

$$PREC = \frac{68}{68 + 3} = \frac{68}{71} = 0,9577 \Rightarrow \text{Precisión} = 95.77\%$$

### Sensibilidad (Recall):

$$RECALL = \frac{68}{68 + 0} = 1,0 \Rightarrow \text{Recall} = 100\%$$

### Especificidad (Specificity):

$$SPEC = \frac{2}{2 + 3} = \frac{2}{5} = 0,4 \Rightarrow \text{Especificidad} = 40\%$$

### Valor Predictivo Negativo (NPV):

$$NPV = \frac{2}{2 + 0} = 1,0 \Rightarrow \text{NPV} = 100\%$$

### F1-Score:

$$F1 = 2 \cdot \frac{0,9577 \cdot 1}{0,9577 + 1} = 0,9787 \Rightarrow \text{F1-Score} = 97.87\%$$

El modelo SVM entrenado muestra un desempeño de una exactitud del **95.89%** y una precisión del **95.77%**. Estos valores indican que el sistema es capaz de clasificar correctamente la gran mayoría de las muestras. El problema que tambien se observa es los pocos datos que tiene el apartado de Reposo, lo cual no tiene un balance entre datos; las causas podrian ser la obtencion de las ventanas y las características

El **recall del 100%** es un signo que algo falla ya que no puede existir un Recall del 100%, significa que el modelo identificó correctamente todos los saltos sin generar falsos negativos ( $FN = 0$ ). La causa podria ser falta de datos.

El **F1-Score del 97.87%** confirma un balance adecuado entre precisión y sensibilidad, lo que podria indicar que el modelo tiene un rendimiento robusto para la clase mayoritaria (salto).

Sin embargo, se observa una **especificidad baja del 40%**, lo que significa que el modelo tuvo dificultades para clasificar correctamente el estado de reposo. De las 5 muestras reales de reposo, solo 2 fueron correctamente identificadas, mientras que 3 fueron clasificadas erróneamente como saltos (falsos positivos). Confirmando la sospecha que pudo existir un desbalance en la cantidad de datos con Reposo, esto no se soluciono por falta de tiempo.

## 4. Conclusiones

En este trabajo se desarrolló un sistema de reconocimiento de actividad física utilizando señales de sensores iniciales y el algoritmo de aprendizaje automático *Support Vector Machine* (SVM). Los resultados obtenidos demuestran que es posible clasificar diferentes estados de actividad (salto y reposo) con un buen nivel de exactitud.

El modelo entrenado alcanzó una exactitud del **95.89%** y un **F1-Score del 97.87%**, lo que nos dice que llega a ser aceptable. La **sensibilidad del 100%** muestra que el sistema fue capaz de detectar todos los saltos correctamente, sin perder ningún evento, lo cual es importante para aplicaciones de monitoreo deportivo o biomédico.

Sin embargo, se identificaron algunos problemas importantes. La **especificidad del 40%** revela que el modelo tuvo problemas para clasificar correctamente el estado de reposo, confundiendo 3 de las 5 muestras de reposo con saltos. Este problema se debe principalmente al desbalance en los datos de entrenamiento: se contó con 68 muestras de salto pero solo 5 de reposo. Esta diferencia tan grande provocó que el modelo aprendiera mejor a reconocer saltos, pero no desarrollara la misma capacidad para identificar el reposo.

Las posibles causas de este desbalance incluyen la metodología utilizada para segmentar las señales en ven-

tanaz de tiempo y la forma en que se extrajeron las características. Por limitaciones de tiempo, no fue posible corregir este problema durante el desarrollo del proyecto, pero se reconoce como el aspecto más importante a mejorar en futuras iteraciones.

A pesar de estas limitaciones, el trabajo cumplió con su objetivo principal: demostrar que los sensores iniciales de bajo costo, combinados con técnicas de aprendizaje automático, pueden ser utilizados efectivamente para reconocer actividades físicas. Esto abre posibilidades para aplicaciones en deportes, rehabilitación y monitoreo de salud.

## Referencias

- [1] Organización Mundial de la Salud. Caídas: datos y estadísticas. OMS; 2023.
- [2] WitMotion. *WT9011DCL IMU Sensor Datasheet*. Shenzhen WitMotion Co., 2024.
- [3] Bulling A, Blanke U, Schiele B. *A tutorial on human activity recognition using body-worn inertial sensors*. ACM Computing Surveys. 2014;46(3):1–33.
- [4] Guyon I, Elisseeff A. *An introduction to variable and feature selection*. J Mach Learn Res. 2003;3:1157–82.

## Anexos

### Anexo A: Protocolo experimental completo

#### A. Protocolo Experimental Completo

#### B. Tabla de Protocolo Experimental

Parámetro	Especificación	Justificación / Referencias
Actividades (3 clases ADL)	<p>1. <b>Estar quieto:</b> Postura estática de referencia.</p> <p>2. <b>Impulso (flexión) para saltar:</b> Preparación neuromuscular.</p> <p>3. <b>Saltando:</b> Ejecución del salto vertical.</p>	Las actividades de salto permiten evaluar potencia muscular, control neuromuscular y capacidad de absorción de impacto, fundamentales en biomecánica deportiva y rehabilitación [1,2].
Justificación biomédica	<p><b>Estar quieto:</b> Línea base para control postural, oscilaciones del centro de masa y ruido del sensor [7,8].</p> <p><b>Impulso/Flexión:</b> Fase de carga excéntrica, activación del reflejo de estiramiento y almacenamiento de energía elástica en tendones [3,4].</p> <p><b>Saltando:</b> Fase de vuelo y aterrizaje. Permite cuantificar aceleración vertical, tiempo de vuelo, altura del salto y simetría [5,6].</p>	Validadas en evaluaciones funcionales como CMJ (Counter Movement Jump) y son predictores de rendimiento atlético y riesgo de lesión [9,10].
Colocación anatómica del sensor	Región lumbar (L4–L5), fijado con banda elástica ajustable en la cintura.	La región lumbar aproxima el centro de masa corporal (CoM), capturando la aceleración vertical total durante el salto [11,12].
Orientación de ejes	<ul style="list-style-type: none"> <li>▪ <b>+X:</b> Anteroposterior (adelante)</li> <li>▪ <b>+Y:</b> Mediolateral (izquierda)</li> <li>▪ <b>+Z:</b> Vertical (arriba)</li> </ul> <p>Sistema: anatómico estándar.</p>	Orientación según convención ISB. El eje Z es crítico para análisis de salto vertical [13].
Ficha técnica del sensor WT9011DCL	<p><b>Acelerómetro:</b> Rango <math>\pm 16g</math>, resolución 16 bits, ruido <math>&lt;0.01\text{ g RMS}</math>.</p> <p><b>Giroscopio:</b> Rango <math>\pm 2000^\circ/\text{s}</math>, resolución 16 bits.</p> <p><b>Magnetómetro:</b> Rango <math>\pm 4900 \mu\text{T}</math>.</p> <p>Frecuencia máxima: 200 Hz.</p> <p>Comunicación: UART, USB, Bluetooth 5.0.</p>	Especificaciones del fabricante WitMotion. El rango de $\pm 16g$ es crítico para capturar impactos de aterrizaje sin saturación [15,16].
Método de conexión empleado	Bluetooth 5.0 mediante aplicación WitMotion o script Python.	Conexión inalámbrica para no restringir el movimiento explosivo del salto. Latencia $<10\text{ ms}$ [Manual WT901].

Parámetro	Especificación	Justificación / Referencias
<b>Pasos de calibración inicial</b>	<ol style="list-style-type: none"> <li><b>Acelerómetro:</b> superficie plana (30s), verificar <math>Z \approx 9.81 \text{ m/s}^2</math>.</li> <li><b>Giroscopio:</b> estático (30s), compensar offset.</li> <li><b>Magnetómetro:</b> movimientos en “8” (30s) – opcional.</li> <li><b>Prueba de rango:</b> caída desde 30 cm, verificar no saturación.</li> <li>Guardar parámetros en memoria.</li> </ol>	Procedimiento estándar IEEE 1293-2018. Prueba de caída específica para estudios de impacto [17,18].
<b>Número de sujetos</b>	$N = 8\text{--}10$ sujetos (distribución equitativa por sexo).	Tamaño adecuado para estudio piloto. Los saltos tienen menor variabilidad inter-sujeto [19].
<b>Criterios de inclusión/exclusión</b>	<p><b>Inclusión:</b> 18–35 años, capaces de saltar sin dolor, sin lesiones agudas, experiencia con saltos.</p> <p><b>Exclusión:</b> Cirugías rodilla/tobillo (&lt;12 meses), tendinopatías activas, trastornos del equilibrio, embarazo, dolor lumbar agudo.</p>	Criterios para minimizar riesgo de lesión y obtener población capaz de ejecutar saltos con técnica adecuada [20,21].
<b>Número de repeticiones por clase</b>	Quieto: 3 repeticiones de 30s. Impulso: 10 repeticiones. Saltando: 10 repeticiones.	Múltiples repeticiones para capturar variabilidad intra-sujeto. Los saltos requieren más repeticiones por fatiga [22,23].
<b>Duración por repetición</b>	Quieto: 30 s. Impulso: 2–3 s. Saltando: 3–4 s.	Duración basada en análisis cinemático del salto vertical. Fase de vuelo típica: 0.4–0.6 s [24,25].
<b>Frecuencia de muestreo</b>	200 Hz.	Frecuencia alta necesaria para capturar impacto de aterrizaje (50–100 ms). Cumple criterio de Nyquist para 0–50 Hz [26,27].
<b>Marcadores de sincronía</b>	Inicio: 2 palmadas + señal verbal. Fin: 3 palmadas. Opcional: video a 120 fps.	Palmadas generan picos identificables ( $>3g$ ). El video permite validación visual [28].
<b>Condiciones del entorno</b>	Superficie: piso de madera o goma eva. Calzado: deportivo propio. Espacio vertical: mín. 3 m. Área segura: 2 m de radio. Iluminación: 400–600 lux. Temperatura: 20–24°C.	Control ambiental para seguridad y reproducibilidad. La superficie influye en la estrategia de aterrizaje [29,30].
<b>Consideraciones éticas</b>	Consentimiento informado escrito, explicación de riesgos, derecho a retirarse, anonimización (S01–S10), almacenamiento seguro, seguro de laboratorio, protocolo de emergencia.	Conforme a la Declaración de Helsinki; los saltos implican mayor riesgo y requieren consentimiento explícito [31].

Parámetro	Especificación	Justificación / Referencias
Riesgos y mitigación	<p><b>Riesgos:</b> lesiones musculoesqueléticas (moderado), fatiga acumulativa (bajo), pérdida de equilibrio (bajo), molestia por sensor (mínimo).</p> <p><b>Mitigación:</b> calentamiento obligatorio (5–10 min), supervisión continua, descansos de 30–45 s entre saltos, criterios claros de detención, superficie semi-amortiguada, instrucción de técnica de aterrizaje, máx. 10 saltos consecutivos.</p>	Análisis según ISO 14971. El calentamiento reduce el riesgo de lesión en 35–50 % [32,33].
Estrategia de segmentación	<p>Segmentación basada en eventos: inicio salto (<math>acc_z &lt; 0,8g</math>), despegue (<math>acc_z &lt; 0,2g</math>), aterrizaje (pico <math>acc_z &gt; 2,5g</math>), ventana -0.5 s a +1.5 s.</p> <p>Para clasificación: ventana 1.28 s (256 muestras) con 50 % de solapamiento.</p>	Segmentación por eventos estándar en análisis de salto; permite extraer características temporales y cinemáticas [34,35].
Formato y convención de nombres	<p>Formato CSV; columnas: timestamp, acc_x, acc_y, acc_z, gyro_x, gyro_y, gyro_z, mag_x, mag_y, mag_z; unidades: m/s<sup>2</sup>, °/s, µT.</p> <p>Nomenclatura: S[ID]_[ACTIVIDAD]_R[REP]_[FECHA].csv.</p> <p>Ejemplo: S01 QUIETO_R01_20251005.csv.</p>	Formato compatible con pandas, MATLAB y R; metadatos esenciales para normalización [36].
Plan de respaldo	<p>Respaldo primario: disco local (RAID 1).</p> <p>Secundario: Google Drive.</p> <p>Terciario: disco externo semanal.</p> <p>Control de versiones: Git privado (GitHub/GitLab).</p> <p>Bitácora: cuaderno de laboratorio y Google Sheets.</p> <p>Integridad: Checksum MD5.</p>	Triple respaldo para prevención de pérdida. El uso de Git garantiza reproducibilidad [37,38].

**Cuadro 2:** Parámetros del protocolo experimental para adquisición de señales de salto.

## B.1. Procedimiento Experimental

### B.1.1. Preparación Previa (20 minutos)

#### Configuración del equipo

1. Verificar carga de batería del sensor ( $\geq 90\%$ )
2. Encender y emparejar vía Bluetooth
3. Configurar parámetros de adquisición:
  - Frecuencia: 200 Hz
  - Rango acelerómetro:  $\pm 16g$
  - Rango giroscopio:  $\pm 2000^\circ/\text{s}$
4. Crear estructura de carpetas para almacenamiento

#### Calibración del sensor

1. Colocar sensor en superficie completamente plana
2. Calibrar acelerómetro (30s):
  - Verificar:  $acc_x, acc_y \in [-0,1, +0,1] \text{ m/s}^2$
  - Verificar:  $acc_z \in [9,7, 10,0] \text{ m/s}^2$
3. Calibrar giroscopio (30s):
  - Verificar:  $gyro_{x,y,z} \in [-2, +2] \text{ }^\circ/\text{s}$
4. Realizar prueba de rango dinámico:
  - Dejar caer sensor desde 30 cm
  - Verificar que no haya saturación ( $acc_z\_max < 16g$ )

#### Preparación del espacio

1. Delimitar área de salto de  $2 \times 2$  metros
2. Verificar ausencia de obstáculos
3. Verificar altura libre mínima de 3 metros
4. Preparar cronómetro
5. Tener disponibles: agua, silla para descansos

### B.1.2. Recepción del Participante (15 minutos)

#### Bienvenida

1. Explicar objetivo del estudio
2. Describir las actividades:
  - Estar quieto de pie (30 segundos, 3 veces)
  - Saltos verticales (10 repeticiones)
3. Mencionar duración total: aproximadamente 40 minutos
4. Explicar riesgos mínimos
5. Resolver dudas

#### Calentamiento obligatorio (10 minutos) Fase 1: Movilidad articular (3 min)

- Circunducción de tobillos: 10 repeticiones cada uno
- Flexo-extensión de rodillas: 15 repeticiones
- Balanceo de piernas: 10 repeticiones cada una
- Rotación de caderas: 10 repeticiones

#### Fase 2: Activación cardiovascular (2 min)

- Marcha en el lugar: 30 segundos
- Elevación de rodillas: 30 segundos
- Desplazamientos laterales: 30 segundos

**Fase 3: Progresión de saltos (5 min)**

- 5 saltos muy pequeños (10 cm)
- 5 saltos pequeños (20 cm)
- 5 saltos medianos (30 cm)
- 3 saltos cerca del máximo (80 % esfuerzo)
- Descanso 1 minuto

*Observar técnica de aterrizaje: antepié primero, rodillas flexionadas, tronco ligeramente inclinado.*

**B.1.3. Colocación del Sensor (5 minutos)**

1. Identificar punto de colocación: tobillo derecho
2. Verificar orientación del sensor:
  - +Z = arriba
  - +X = adelante
  - +Y = izquierda
3. Fijar con banda elástica ancha
4. Ajuste firme pero cómodo
5. Verificar transmisión en tiempo real
6. Realizar movimientos de prueba

**B.1.4. Adquisición de Datos (25-30 minutos)**

**ACTIVIDAD 1: Estar Quietos** *Instrucciones al participante: "Permanece de pie lo más quieto/a posible durante 30 segundos. Mantén los brazos relajados, pies al ancho de hombros, y mira hacia un punto fijo."*

**Para cada repetición (3 repeticiones):**

1. Posicionar al participante correctamente
2. Decir: "Preparado/a... en 3, 2, 1..."
3. Realizar 2 palmadas audibles
4. Iniciar grabación: S[ID]\_QUIETO\_R0[1-3].csv
5. Iniciar cronómetro (30 segundos)
6. A los 30s: "Perfecto, ya puedes moverte"
7. Realizar 3 palmadas audibles
8. Detener grabación
9. Descanso: 30 segundos

**Verificación:**  $acc_z$  debe oscilar alrededor de  $9.81 \text{ m/s}^2$  con amplitud  $< 0,5 \text{ m/s}^2$

**ACTIVIDAD 2: Saltando** *Instrucciones al participante: "Salta verticalmente lo más alto que puedas de forma cómoda. Usa los brazos naturalmente. Aterriza suave, con las rodillas flexionadas. Vamos a hacer 10 saltos con descanso entre cada uno."*

**Recordatorio de seguridad:**

- Aterrizar con antepié primero
- Rodillas flexionadas al aterrizar
- Absorber impacto progresivamente

**Para cada repetición (10 repeticiones):**

1. Posición inicial en área de salto
2. Decir: "Salto [número]... Cuando estés listo/a..."
3. Realizar 2 palmadas audibles
4. Dar señal: "¡Salta!"
5. Iniciar grabación: S[ID]\_SALTO\_R[01-10].csv
6. Participante ejecuta salto completo
7. Una vez estabilizado: ".Excelente"

8. Realizar 3 palmadas audibles
9. Detener grabación
10. Descanso obligatorio: 45 segundos
11. Preguntar: "¿Cómo te sientes?"

**Verificación:** Debe observarse pico de impacto claro al aterrizar ( $acc_z > 3g$ ) y fase de vuelo ( $acc_z \approx 0$ )

**Descanso intermedio:** Después del salto 5, descanso extendido de 2-3 minutos

#### B.1.5. Finalización (10 minutos)

##### Retiro del sensor

1. Agradecer al participante
2. Retirar banda elástica y sensor
3. Preguntar sobre comodidad y sensaciones

##### Verificación de datos

1. Contar archivos generados:
  - QUIETO: 3 archivos
  - SALTO: 10 archivos
  - **TOTAL: 13 archivos esperados**
2. Verificar tamaño y estructura de archivos
3. Abrir un archivo de cada actividad para inspección visual
4. Generar gráficas rápidas para validación

##### Respaldo

1. Copiar carpeta completa: /Sesión\_[FECHA]/S[ID]/
2. Respaldar en disco local
3. Sincronizar con almacenamiento en nube
4. Verificar integridad de archivos

## C. CONSENTIMIENTO INFORMADO PARA PARTICIPACIÓN EN ESTUDIO

**Título del estudio:** Adquisición de señales inerciales durante actividades de salto

**Investigadores responsables:** [Nombres del equipo - Equipo 5]

**Institución:** [Universidad Autonoma de Mexico - Facultad de Ciencias]

---

### Propósito del estudio

Este estudio tiene como objetivo registrar señales de movimiento durante actividades de salto vertical utilizando un sensor de movimiento inercial (acelerómetro y giroscopio) no invasivo. Los datos servirán para desarrollar algoritmos de reconocimiento de actividades físicas.

### Procedimientos

Si acepta participar:

1. Se le colocará un sensor pequeño ( $35 \times 26 \times 11$  mm, 12 g) en la espalda baja, fijado con una banda elástica ajustable.
2. Realizará un calentamiento supervisado de 10 minutos.
3. Realizará 3 tipos de actividades:
  - Permanecer quieto de pie: 3 repeticiones de 30 segundos
  - Flexión preparatoria (sin saltar): 10 repeticiones
  - Saltos verticales: 10 repeticiones
4. La sesión completa durará aproximadamente 40 minutos.
5. Un investigador capacitado estará presente en todo momento.

### Riesgos

Los riesgos asociados incluyen:

Los riesgos asociados a la actividad incluyen, en orden de mayor a menor probabilidad, la posibilidad de una lesión musculoesquelética como un esguince o distensión durante los saltos, considerado un **riesgo moderado** que se minimiza con un calentamiento obligatorio, supervisión continua y descansos adecuados; un **riesgo bajo** de experimentar fatiga muscular o molestia articular temporal; y un **riesgo mínimo** de sentir alguna molestia derivada del uso del sensor o la banda elástica.

**IMPORTANTE:** Debe detener la actividad inmediatamente y notificar al investigador si experimenta:

- Dolor agudo en rodillas, tobillos o espalda
- Mareo o pérdida de equilibrio
- Dificultad para respirar
- Cualquier otra molestia significativa

### Confidencialidad

- Se le asignará un código anónimo (ejemplo: S01).
- Su nombre NO se registrará en los archivos de datos.
- Solo se recopilarán datos demográficos básicos (edad, sexo, peso, estatura) sin información identificable.
- Los datos se almacenarán en servidores seguros con acceso restringido al equipo de investigación.
- Los resultados publicados solo incluirán datos agregados, nunca información individual identificable.

### Voluntariedad y derecho a retirarse

Su participación es completamente **voluntaria**. Puede:

- Negarse a participar sin ninguna consecuencia
- Retirarse en cualquier momento durante la sesión sin dar explicaciones
- Solicitar que sus datos sean eliminados (hasta antes del análisis agregado)

**Declaración de consentimiento**

He leído (o me han leído) la información anterior. He tenido la oportunidad de hacer preguntas y todas mis preguntas han sido respondidas satisfactoriamente. Entiendo los procedimientos y riesgos. Acepto participar voluntariamente en este estudio.

**Nombre del participante:** \_\_\_\_\_

**Firma:** \_\_\_\_\_ **Fecha:** \_\_\_\_\_

**Nombre del investigador:** \_\_\_\_\_

**Firma:** \_\_\_\_\_ **Fecha:** \_\_\_\_\_

## D. Referencias Bibliográficas

1. Bobbert MF, Van Ingen Schenau GJ. Coordination in vertical jumping. *J Biomech.* 1988;21(3):249-62.
2. Markovic G, Jaric S. Is vertical jump height a body size-independent measure of muscle power? *J Sports Sci.* 2007;25(12):1355-63.
3. Komi PV. Stretch-shortening cycle: a powerful model to study normal and fatigued muscle. *J Biomech.* 2000;33(10):1197-206.
4. Wilson GJ, et al. The optimal training load for the development of dynamic athletic performance. *Med Sci Sports Exerc.* 1993;25(11):1279-86.
5. Linthorne NP. Analysis of standing vertical jumps using a force platform. *Am J Phys.* 2001;69(11):1198-204.
6. Glatthorn JF, et al. Validity and reliability of Optojump photoelectric cells for estimating vertical jump height. *J Strength Cond Res.* 2011;25(2):556-60.
7. Winter DA, et al. Medial-lateral and anterior-posterior motor responses associated with centre of pressure changes in quiet stance. *Neurosci Res Commun.* 1993;12(3):141-8.
8. Paillard T, Noé F. Techniques and methods for testing the postural function in healthy and pathological subjects. *Biomed Res Int.* 2015;2015:891390.
9. Cormack SJ, et al. Reliability of measures obtained during single and repeated countermovement jumps. *Int J Sports Physiol Perform.* 2008;3(2):131-44.
10. Taylor KL, et al. Fatigue monitoring in high performance sport: A survey of current trends. *J Aust Strength Cond.* 2012;20(1):12-23.
11. Moe-Nilssen R, Helbostad JL. Trunk accelerometry as a measure of balance control during quiet standing. *Gait Posture.* 2002;16(1):60-8.
12. Mayagoitia RE, et al. Standing balance evaluation using a triaxial accelerometer. *Gait Posture.* 2002;16(1):55-9.
13. Wu G, et al. ISB recommendation on definitions of joint coordinate systems. *J Biomech.* 2002;35(4):543-8.
14. Baca A. Innovative diagnostic methods in elite sport. *Br J Sports Med.* 2006;40(Suppl 1):i6-10.
15. WitMotion. WT901 Series IMU Datasheet. 2023. [Manual técnico]
16. Picerno P, et al. 25 years of lower limb joint kinematics by using inertial and magnetic sensors. *Gait Posture.* 2017;51:413-28.
17. IEEE Std 1293-2018. IEEE Standard Specification Format Guide for Linear, Single-Axis, Digital, Torque-Balance Accelerometer. 2018.
18. Ferraris F, et al. Procedure for effortless in-field calibration of three-axis rate gyros and accelerometers. *Sens Mater.* 1995;7:311-30.
19. McMahon JJ, et al. Understanding the key phases of the countermovement jump force-time curve. *Strength Cond J.* 2018;40(4):96-106.
20. Goble DJ, et al. The influence of horizontal velocity on interlimb symmetry in normal walking. *Hum Mov Sci.* 2003;22(3):271-83.
21. Hewett TE, et al. Biomechanical measures of neuromuscular control and valgus loading of the knee predict anterior cruciate ligament injury risk. *Am J Sports Med.* 2005;33(4):492-501.
22. Requena B, et al. Reliability and validity of a wireless microelectromechanicals based system (Keimove<sup>TM</sup>) for measuring vertical jumping performance. *J Sports Sci Med.* 2012;11(1):115-22.
23. Castagna C, et al. Effects of intermittent-endurance fitness on match performance in young male soccer players. *J Strength Cond Res.* 2009;23(7):1954-9.
24. Kibele A. Possibilities and limitations in the biomechanical analysis of countermovement jumps. *Studies Phys Cult Tourism.* 1998;5:15-23.
25. Moir GL. Three different methods of calculating vertical jump height from force platform data in men and women. *Meas Phys Educ Exerc Sci.* 2008;12(4):207-18.
26. Winter DA. Biomechanics and motor control of human movement. 4th ed. Hoboken: Wiley; 2009.
27. Robertson G, et al. Research methods in biomechanics. 2nd ed. Champaign: Human Kinetics; 2014.
28. Zijlstra W, Hof AL. Assessment of spatio-temporal gait parameters from trunk accelerations during human walking. *Gait Posture.* 2003;18(2):1-10.
29. Ford KR, et al. Use of an overhead goal alters vertical jump performance and biomechanics. *J Strength Cond Res.* 2005;19(2):394-9.
30. McNitt-Gray JL. Kinetics of the lower extremities during drop landings from three heights. *J Biomech.*

- 1993;26(9):1037-46.
31. World Medical Association. World Medical Association Declaration of Helsinki: ethical principles for medical research involving human subjects. JAMA. 2013;310(20):2191-4.
  32. Fradkin AJ, et al. Effects of warming-up on physical performance: a systematic review with meta-analysis. J Strength Cond Res. 2010;24(1):140-8.
  33. Woods K, et al. Warm-up and stretching in the prevention of muscular injury. Sports Med. 2007;37(12):1089-99.
  34. Mathie MJ, et al. A system for monitoring posture and physical activity using accelerometers. Proc 25th Annu Int Conf IEEE Eng Med Biol Soc. 2003;1:365-8.
  35. Bouten CV, et al. A triaxial accelerometer and portable data processing unit for the assessment of daily physical activity. IEEE Trans Biomed Eng. 1997;44(3):136-47.
  36. Godfrey A, et al. Direct measurement of human movement by accelerometry. Med Eng Phys. 2008;30(10):1364-86.
  37. Peng RD. Reproducible research in computational science. Science. 2011;334(6060):1226-7.
  38. Donoho DL. An invitation to reproducible computational research. Biostatistics. 2010;11(3):385-8.
  39. Sáez de Villarreal, E. S. (2004). Variables determinantes en el salto vertical. Revista Digital EFDeportes, Año 10 (N.º 70). Recuperado de <https://www.efdeportes.com/efd70/salto.htm>
  40. Viladot Voegeli, A. (2003). Anatomía funcional y biomecánica del tobillo y el pie. Revista Española de Reumatología, 30(9), 469–477. Recuperado el 2 de noviembre de 2025, de <https://www.elsevier.es/es-revista-revista-espanolareumatologia-29-articulo-anatomia-funcionalbiomecanica-del-tobillo-13055077>
  41. Brockett, C. L., Chapman, G. J. (2016). Biomechanics of the ankle. En Procedia Engineering (Vol. 147, pp. 180-187). Recuperado el 2 de noviembre de 2025 de <https://www.sciencedirect.com/science/article/pii/S1877132716300483>

## Anexo B: Tabla completa de características y justificación

**Cuadro 3:** Conjunto de características seleccionadas para la extracción de información del acelerómetro y giroscopio.

Característica	Dominio	Definición breve	Unidad	Justificación	Observación
RMS (Ax)	Tiempo	Raíz cuadrada del promedio de los cuadrados de Ax	m/s <sup>2</sup>	Mide la intensidad del movimiento; distingue entre reposo y actividad [?, ?, ?].	Muy usado en reconocimiento de actividades humanas.
Varianza (Ay)	Tiempo	Dispersión de los valores de Ay	(m/s <sup>2</sup> ) <sup>2</sup>	Mide irregularidad del movimiento lateral.	Alta varianza en actividades dinámicas.
Media (Az)	Tiempo	Promedio de Az en una ventana	m/s <sup>2</sup>	Indica orientación respecto a la gravedad.	Permite distinguir posturas o inclinaciones.
Energía total (Axyz)	Tiempo	Suma de cuadrados $Ax^2 + Ay^2 + Az^2$	(m/s <sup>2</sup> ) <sup>2</sup>	Cuantifica la energía del movimiento global.	Aumenta con la intensidad de la actividad.
Jerk promedio	Tiempo	Derivada temporal del vector aceleración	m/s <sup>3</sup>	Detecta cambios bruscos o transiciones rápidas.	Útil para actividades con sacudidas o gestos rápidos.
Frecuencia dominante (Az)	Frecuencia	Frecuencia del pico máximo del espectro de Az	Hz	Relacionada con la cadencia del movimiento (p.ej., pasos al caminar).	Útil para actividades periódicas.
Entropía espectral (Az)	Frecuencia	Mide la complejidad o dispersión del espectro de Az	adimensionado	Distingue entre movimientos regulares e irregulares.	Alta en movimientos caóticos (como correr).
Correlación Ax-Ay	Tiempo	Correlación lineal entre ejes Ax y Ay	-	Indica coordinación entre ejes de movimiento.	Baja en gestos asimétricos o rotaciones.
Varianza (Wz)	Tiempo	Dispersión de la velocidad angular en eje Z	(°/s) <sup>2</sup>	Mide la variabilidad del giro o rotación.	Aumenta al realizar giros repetidos.
Energía rotacional (Wxyz)	Tiempo	Suma de cuadrados $wx^2 + wy^2 + wz^2$	(°/s) <sup>2</sup>	Representa la energía rotacional total.	Aumenta con la velocidad de rotación.

Bao Intille, 2004; Kwapisz et al., 2011; Anguita et al., 2013 para “Human Activity Recognition Using Smartphones”

## Anexo C: Resultados detallados y curvas de desempeño

Agregue gráficos adicionales, como curvas ROC o comparaciones por sujeto.

## Anexo D: Dataset y bitácora

Se realizó la adquisición de datos para el proyecto de Reconocimiento de Actividades de la Vida Diaria. Se le pidió al sujeto permanecer en reposo durante 30 segundos, seguido de una serie de 10 saltos, cada uno separado por

un intervalo de 2 segundos. Esta señal se registró utilizando sensores de aceleración y velocidad angular, con el objetivo de analizar los diferentes estados de actividad.

Posteriormente, se segmentó la señal en ventanas de duración definida según el protocolo, con solapamiento suficiente para capturar de manera adecuada las transiciones entre reposo e impulso de salto. Cada ventana fue etiquetada según la actividad correspondiente, permitiendo separar claramente segmentos de reposo, impulsos y saltos completos.

A cada ventana se le calcularon características tanto en dominio de tiempo como en dominio de frecuencia. Entre las características de dominio de tiempo se incluyeron el RMS del eje X, la varianza del eje Y, la media del eje Z, la energía total de los tres ejes y el jerk promedio. En el dominio de frecuencia se calcularon la frecuencia dominante y la entropía espectral del eje Z, la correlación entre los ejes X y Y, la varianza de la velocidad angular en Z y la energía rotacional de los tres ejes. Todas estas características se organizaron en una matriz donde cada fila correspondía a una ventana y cada columna a una característica específica.

Para cada modelo se calcularon métricas de desempeño tales como accuracy, F1-macro, precision y recall por clase, y se generaron matrices de confusión para identificar errores de clasificación comunes. Finalmente, se compararon los resultados entre los distintos modelos y se analizó qué actividades eran más propensas a confundirse. Con base en este análisis, se determinó el modelo más adecuado para el reconocimiento de actividades y se justificó la selección en función de su precisión, capacidad de generalización y estabilidad frente a distintos sujetos.

#### Anexo E: Repositorio GitHub documentado

```

1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 from scipy.signal import find_peaks, butter, filtfilt, welch
5 from sklearn.feature_selection import f_classif, mutual_info_classif, RFE
6 from sklearn.svm import SVC
7 from sklearn.ensemble import RandomForestClassifier
8 from sklearn.model_selection import StratifiedKFold
9 from sklearn.metrics import accuracy_score, f1_score, precision_score, recall_score,
   confusion_matrix
10 from sklearn.neighbors import KNeighborsClassifier
11 from sklearn.preprocessing import StandardScaler
12 import os
13 import datetime
14 import seaborn as sns
15
16 # -----
17 # Par metros (ajusta aqu )
18 FILENAME = "SUGETO1_M_ESTUDIOCOMPLETO1.txt"
19 window_s = 1.0
20 overlap = 0.5
21 min_peak_distance_s = 1.5
22 jump_prominence = 0.2
23 flight_thresh_g = 0.4
24 g_ref = 1.0
25 # -----
26
27 def read_txt_file(filepath):
28     df = pd.read_csv(filepath, sep=r'\s+', engine='python', comment='#', header=0)
29     return df
30
31 def parse_time_column(df):
32     if 'Time(s)' in df.columns:
33         try:
34             times = df['Time(s)'].astype(str)
35             tsecs = []
36             base = None
37             for t in times:
38                 dt = datetime.datetime.strptime(t, "%H:%M:%S.%f")
39                 if base is None:
40                     base = dt
41                     tsecs.append(0.0)
42                 else:
43                     diff = (dt - base).total_seconds()
44                     if diff < 0:
45                         diff += 24*3600
46                     tsecs.append(diff)
47             df['time_s'] = np.array(tsecs, dtype=float)
48         except Exception:
49             df['time_s'] = df['Time(s)'].astype(float)
50     else:
```

```

51     raise ValueError("No hay columna 'Time(s)' en el archivo.")
52     return df
53
54 def infer_fs(df):
55     t = df['time_s'].values
56     dt = np.diff(t)
57     median_dt = np.median(dt)
58     if median_dt <= 0:
59         return 125.0
60     return 1.0/median_dt
61
62 def butter_lowpass(cutoff, fs, order=4):
63     nyq = 0.5 * fs
64     normal_cutoff = cutoff / nyq
65     b, a = butter(order, normal_cutoff, btype='low', analog=False)
66     return b, a
67
68 def lowpass_filter(x, cutoff, fs, order=4):
69     b,a = butter_lowpass(cutoff, fs, order=order)
70     return filtfilt(b,a,x)
71
72 def compute_magnitude(df):
73     ax = df['ax(g)'].values
74     ay = df['ay(g)'].values
75     az = df['az(g)'].values
76     mag = np.sqrt(ax**2 + ay**2 + az**2)
77     df['a_mag'] = mag
78     return df
79
80 def detect_jumps(df, fs, min_peak_distance_s=1.5, prominence=0.2):
81     az = df['az(g)'].values
82     distance = int(min_peak_distance_s * fs)
83     peaks, props = find_peaks(az, distance=distance, prominence=prominence)
84     return peaks, props
85
86 def detect_flight_segments(df, fs, flight_thresh_g=0.4):
87     mag = df['a_mag'].values
88     is_flight = mag < flight_thresh_g
89     segments = []
90     in_seg = False
91     for i,v in enumerate(is_flight):
92         if v and not in_seg:
93             s = i
94             in_seg = True
95         if not v and in_seg:
96             e = i-1
97             segments.append((s,e))
98             in_seg = False
99     if in_seg:
100        segments.append((s, len(is_flight)-1))
101    return segments
102
103 def sliding_windows(df, window_s, overlap, fs):
104     step = window_s * (1 - overlap)
105     step_samples = int(round(step * fs))
106     win_samples = int(round(window_s * fs))
107     N = len(df)
108     starts = np.arange(0, N - win_samples + 1, step_samples, dtype=int)
109     windows = [(s, s + win_samples) for s in starts]
110     return windows
111
112 # -----
113 # Features
114 # -----
115 def rms(x):
116     return np.sqrt(np.mean(x**2))
117
118 def total_energy_xyz(ax,ay,az):
119     return np.sum(ax**2 + ay**2 + az**2)
120
121 def spectral_entropy(signal, fs, nperseg=None):
122     f, Pxx = welch(signal, fs=fs, nperseg=nperseg or min(256, len(signal)))
123     Pxx_norm = Pxx / np.sum(Pxx) if Pxx.sum()>0 else Pxx
124     Pxx_norm = np.where(Pxx_norm==0, 1e-12, Pxx_norm)
125     se = -np.sum(Pxx_norm * np.log2(Pxx_norm))
126     return se
127
128 def dominant_frequency(signal, fs):

```

```

129     f, Pxx = welch(signal, fs=fs, nperseg=min(256, len(signal)))
130     idx = np.argmax(Pxx)
131     return f[idx]
132
133 def avg_jerk(ax, ay, az, fs):
134     a_mag = np.sqrt(ax**2 + ay**2 + az**2)
135     jerk = np.diff(a_mag) * fs
136     return np.mean(np.abs(jerk)) if len(jerk)>0 else 0.0
137
138 def compute_features_for_window(df, s, e, fs):
139     ax = df['ax(g)'].values[s:e]
140     ay = df['ay(g)'].values[s:e]
141     az = df['az(g)'].values[s:e]
142     wx = df['wx(deg/s)'].values[s:e]
143     wy = df['wy(deg/s)'].values[s:e]
144     wz = df['wz(deg/s)'].values[s:e]
145     a_mag = df['a_mag'].values[s:e]
146     feats = {}
147     feats['RMS_Ax'] = rms(ax)
148     feats['Var_Ay'] = np.var(ay, ddof=1) if len(ay)>1 else 0.0
149     feats['Mean_Az'] = np.mean(az)
150     feats['Energy_Axyz'] = total_energy_xyz(ax, ay, az)
151     feats['Avg_Jerk'] = avg_jerk(ax, ay, az, fs)
152     feats['DomFreq_Az'] = dominant_frequency(az, fs)
153     feats['SpecEntropy_Az'] = spectral_entropy(az, fs)
154     feats['Corr_Ax_Ay'] = np.corrcoef(ax, ay)[0,1] if len(ax)>1 else 0.0
155     feats['Var_Wz'] = np.var(wz, ddof=1) if len(wz)>1 else 0.0
156     feats['Energy_Wxyz'] = np.sum(wx**2 + wy**2 + wz**2)
157     feats['Mean_Amag'] = np.mean(a_mag)
158     feats['Std_Amag'] = np.std(a_mag, ddof=1)
159     return feats

```

**Listing 1:** proyecto\_saltos\_pipeline\_corregido.py

Para las instrucciones de instalacion den README:

- Se inicializó el repositorio Git en la carpeta del proyecto:

```
git init
```

- Se añadió el repositorio remoto de GitHub:

```
git remote add origin https://github.com/Arandy-GN/proyecto_integrativo_2.git
```

- Se agregaron los archivos al área de preparación:

```
git add .
```

- Se realizó el primer commit con el mensaje:

```
git commit -m "Primera versión del proyecto integrativo completa"
```

- Se creó y renombró la rama principal:

```
git branch -M main
```

- Finalmente, se realizó el envío del proyecto al repositorio remoto:

```
git push -u origin main
```